Pemetaan Potensi Lahan Jagung Menggunakan Citra Satelit Dan Random Forest Pada Cloud computing Google Earth Engine

Studi Kasus di 10 Kabupaten Jawa Timur

(Mapping Corn Potential Area Using Satellite Imagery And Random Forest On Google Earth Engine Cloud Computing)

Dwi Wahyu Triscowati¹, Widyo Pura Buana², Arif Handoyo Marsuhandi²

¹Badan Pusat Statistik Kabupaten Banyuwangi ²Badan Pusat Statistik RI Email: trisco@bps.go.id

ABSTRAK

Ketersediaan informasi potensi lahan baku jagung yang cepat terbaharui penting untuk menduk'ung pemulihan ekonomi pasca covid-19. Pemetaan jagung menjadi tantangan karena jagung lebih banyak ditanam pada areal bukan sawah, sehingga luas baku sawah (LBS) tidak dapat dianggap sebagai luas baku jagung seperti pada padi. Permasalahan lainnya, perlu sumberdaya komputasi yang tinggi jika pemetaan dilakukan secara langsung ataupun manual. Dalam penelitian ini dilakukan pembentukan model klasifikasi dan pemetaan potensi lahan baku jagung di Jawa Timur pada kabupaten terpilih secara otomatis menggunakan Machine learning pada cloud computing google earth engine (GEE). Dengan penggunaan cloud computing, pemetaan dapat dilakukan pada area luas tanpa terkendala kemampuan komputer. Penelitian ini menggunakan algoritma pembelajaran mesin Random Forest (RF) berbasis piksel dengan input data dari satelit Landsat-8, Sentinel-1 dan Sentinel-2. Model klasifikasi kemudian diaplikasikan pada 10 kabupaten dimana hasil terbaik adalah pada Kabupaten Banyuwangi dengan akurasi 0.89. Luas potensi lahan jagung bulanan pada daerah Banyuwangi berkisar antara 22.256,82 - 58.992,3 Ha. Dari hasil kajian ini terbukti bahwa penggunaan cloud computing dapat melakukan penghitungan pada 10 kabupaten secara cepat baik dari sisi pembangunan model maupun prediksinya. Selain itu, dengan penggunaan cloud computing, pemanfaatan citra satelit dapat dimanfaatkan secepat mungkin setelah citra satelit terbit/rilis sehingga prediksi dari potensi jagung dapat secara cepat dan tepat dihasilkan. Kajian ini juga menyoroti kekurangan yang terjadi yaitu dari sisi jumlah sampel untuk data latih dan keterbatasan algoritma yang digunakan sehingga kedepannya dapat dikembangkan lebih baik lagi.

Kata kunci: Cloud computing, Satellite imagery, Machine learning, Potensi lahan jagung, Kerangka Sampel Area.

ABSTRACT

The availability of information on the potential of corn fields that is quickly updated is important to support economic recovery after covid 19. Maize mapping is a challenge in agriculture because the corn planting area does not have special characteristics such as rice fields, corn does not have a standard area map, and planting can be done in rice fields and dry forest lands. Another problem is the need for high computational resources if the mapping of maize is done directly or manually identified. In this study, mapping the potential of maize in East Java in selected districts automatically using machine learning on cloud computing google earth engine. With the use of GEE cloud computing, maize mapping can be carried out in large areas without being constrained by computer capabilities. This study uses a pixel-based Random Forest (RF) machine learning algorithm with input data from the Landsat-8, Sentinel-1 and Sentinel-2 satellites, The classification model was then applied to 10 districts where the best result was Banyuwangi Regency with an accuracy of 0.89. Judging from the potential area of corn in the Banyuwangi area, the area ranges from 22,256.82 - 58,992.3 Ha based on pixels that are predicted to be corn at least 3 times/month. From the results of this study, it is evident that the use of cloud computing can perform calculations in 10 districts quickly, both in terms of model development and predictions. In addition, because it uses cloud computing, the use of satellite imagery can be utilized as soon as possible after the satellite image is published/released so that predictions of the potential of corn can be quickly and accurately generated. This study also highlights the shortcomings that occur, namely in terms of the number of samples for training data and the limitations of the algorithm used so that in the future it can be developed even better.

Keywords: Cloud computing, Satellite imagery, Random Forest, Maize field potential, Area Sampling Frame.

PENDAHULUAN

Sektor pertanian termasuk subsektor tanaman pangan terbukti mampu bertahan dalam gencatan Covid-19. Saat pertumbuhan ekonomi nasional terkontraksi sebesar 2.07, sektor pertanian bertahan tumbuh 1.75 persen (BPS, 2021). Dua komoditas utama tanaman pangan di Indonesia adalah padi dan jagung (Bappenas,

2014). Sebagai dukungan terhadap proses pemulihan ekonomi nasional, maka potensi subsektor tanaman pangan, khususnya komoditas unggulan perlu ditingkatkan kembali.

Sebagai pondasi awal peningkatan potensi pertanian, maka diperlukan adanya peta dasar lahan pertanian atau luas baku lahan pertanian. Luas baku lahan pertanian penting untuk kebijakan peningkatan produksi, evaluasi provitas, prediksi hasil tanaman, basis dasar untuk survei pertanian, maupun hal-hal lain yang terkait. Adanya luas baku lahan pertanian juga penting untuk pengendalian alih fungsi lahan pertanian menjadi lahan lain seperti industri atau perumahan. Oleh karena pentingnya lahan dasar pertanian ini maka DPR menerbitkan UU No.41 tahun 2009 tentang Lahan Pertanian Pangan Berkelanjutan atau LP2B (Bappenas, 2015)

Lahan pertanian dibedakan menjadi lahan pertanian sawah dan lahan pertanian bukan sawah (ladang, tegal/kebun, ladang/huma, dan lahan pertanian yang sedang tidak diusahakan). Luas baku lahan sawah (LBS) ini yang digunakan sebagai dasar identifikasi tanaman padi (BPS, 2015). Saat ini proses penghitungan LBS dilakukan oleh BIG menggunakan citra satelit. Pedoman intrepetasi citra satelit terhadap lahan sawah tertuang dalam keputusan deputi bidang informasi geospasial tematik BIG No 4 tahun 2020.

Berbeda dengan padi, jagung tidak dapat diidentifikasi di lahan sawah saja. Hasil Survei Ubinan 2020 menunjukkan sekitar 71,40 persen rumah tangga jagung melakukan budidaya jagung di lahan bukan sawah. Tanaman jagung yang ditanam di lahan bukan sawah umumnya memiliki produktivitas yang lebih tinggi dibandingkan jika ditanam di lahan lain (BPS, 2021). Bahkan jagung juga di tanam pada lahan-lahan kering maupun diantara pepohonan hutan yang baru ditanam. Akibatnya LBS tidak cukup untuk menggambarkan potensi lahan yang pernah ditanami jagung atau luas baku lahan jagung. Saat ini peta potensi luas baku lahan jagung belum tersedia secara resmi pada instansi terkait.

Sebagaimana penyusunan peta LBS, salah satu cara penyusunan peta potensi luas baku lahan jagung dapat dilakukan dengan melakukan klasifikasi tutupan lahan menggunakan suatu citra satelit. Piksel-piksel pada citra satelit diklasifikasikan sebagai piksel yang sedang ditanami jagung atau bukan jagung setiap bulannya. Dalam penelitian ini, luas baku lahan jagung didefinisikan sebagai daerah citra satelit pada areal penelitian yang terklasifikasi sebagai jagung sekurang-kurangnya selama 3 bulan dalam 1 tahun.

Citra satelit merupakan salah satu *big data* yang sangat berguna untuk mengukur tutupan lahan, mengelompokkan penggunaan lahan, dan lain-lain. *Big data* menurut Furht dan Villanustre (2016) adalah sekumpulan dataset yang sangat besar dan kompleks, dimana penggunaan pengolahan data tradisional dan *onhand database management tools* dalam proses pengolahannya menjadi sangat sulit. Lebih jauh mengenai *big data* digambarkan menjadi tiga karakteristik utama yaitu: volume, kecepatan dan variasi. Kemajuan teknologi telah memudahkan pengumpulan serta pengolahan sejumlah besar data sehingga pemanfaatan *big data* dapat digunakan oleh *official statistics*.

Pemanfaatan citra satelit merupakan suatu tantangan yang perlu dihadapi. Selain teknologi, salah satu faktor suksesnya pemanfaatan *big data* adalah analisis yang digunakan. Agar proses klasifikasi citra satelit tidak dilakukan secara manual, maka klasifikasi dilakukan menggunakan-*Machine learning*. *Machine learning* merupakan metode yang dapat mendeteksi pola-pola hubungan antara sekumpulan data prediktor (variabel independent) dengan data yang perlu diprediksi (variabel dependent). Salah satu metode *Machine learning* yang popular digunakan adalah *Random Forest*. *Random Forest* (Breiman 2001) merupakan metode klasifikasi berbasis *ensemble learning* yang menghasilkan akurasi tinggi dan stabil. Dalam prakteknya, *Random Forest* telah banyak digunakan mengklasifikasikan citra satelit seperti yang dilakukan oleh Pal (2005), Gislason et al. (2006), Marsuhandi et al. (2019), Triscowati et al. (2019).

Penggunaan jenis citra atau indeks turunan yang mampu menggambarkan karakteristik suatu tanaman juga merupakan salah satu kunci keberhasilan deteksi tanaman selain kemampuan metode machine learning dalam menangkap pola tanaman adalah. Citra satelit optik seperti Landsat-8 dan Sentinel-2 memiliki jumlah band yang banyak sehingga memberikan informasi yang lebih kompleks (USGS, 2019). Sayangnya citra optik tidak tembus awan sehingga datanya kurang baik untuk wilayah yang berawan tinggi. Citra satelit jenis radar seperti Sentinel 1 mampu tembus awan sehingga tidak ada area yang bernilai 0 karena awan. Akan tetapi jumlah band pada radar lebih terbatas. Penggunaan kombinasi dari berbagai jenis citra satelit diharapkan mampu mengisi kelemahan dari masing-masing citra sehingga hasil klasifikasi menjadi lebih baik. Contoh lainnya, penambahan indeks yang diyakini mampu mencerminkan tanaman jagung misalnya indeks Visible Atmospherically Resistant Index (VARI). VARI merupakan indeks yang digunakan untuk mendeteksi biomassa daun hijau pada tajuk jagung (Ballesteros, et al., 2020; Vina, A et al., 2004).

Oleh karena data citra satelit merupakan data yang besar dan kompleks, selain metode pengolahannya, diperlukan juga komputer dengan spesifikasi dan memori yang tinggi. Ketersediaan komputer menjadi tantangan tersendiri karena biayanya mahal. Salah satu cara mengatasi proses komputasi yang memerlukan spesifikasi tinggi adalah proses komputasi dilakukan di server atau komputasi awan. Fasilitas komputasi awan saat ini telah tersedia di Google earth engine melalui alamat code earthengine.com. Adanya fasilitas dari GEE

ini memudahkan proses klasifikasi atau pemetaan citra satelit pada area yang luas bahkan sampai area benua (Jiong, J et al., 2015; Gumma, MK et al., 2020)

Berdasarkan pentingnya ketersediaan peta potensi luas baku lahan jagung dan tantangan penyediaannya, maka perlu dilakukan penyusunan peta potensi lahan baku jagung. Tujuan pertama penelitian ini adalah membentuk model klasifikasi lahan jagung menggunakan citra satelit dan *Random Forest* pada *cloud computing* google earth engine serta menghitung akurasi model. Tujuan kedua adalah prediksi peta potensi luas lahan baku jagung menggunakan model klasifikasi yang terbentuk.

Proses penyusunan peta dilakukan dengan melakukan klasifikasi citra satelit menggunakan *Machine learning* pada *cloud computing* google earth engine. Data informasi untuk proses klasifikasi menggunakan hasil pendataan survei KSA Jagung. Kemudian dari hasil klasifikasi citra setiap bulan, akan dipilih piksel yang minimal 3 kali terklasifiksi jagung sebagai piksel potensi luas baku lahan jagung. Peta total potensi luas baku lahan jagung adalah peta berisi keseluruhan piksel terpilih.

Sebagai studi kasus, fokus penelitian dilakukan di Kabupaten-kabupaten pada Provinsi Jawa Timur. Citra satelit yang digunakan adalah Landsat-8, Sentinel-2, dan Sentinel-1 dan indeks turunannya seperti NDVI, EVI, NDWI, NDBI, dan VARI.

METODE

Random Forest

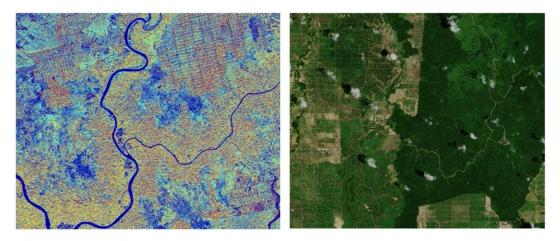
Random Forest merupakan suatu kombinasi dari banyak pohon prediksi dimana tiap pohon bergantung pada nilai dari vektor contoh acak yang saling bebas dan berdistribusi sama pada semua pohon yang ada didalam Random Forest (Breiman 2001). Random Forest memiliki tahapan yang mirip dengan bagging dalam resampling dan voting, namun yang berbeda adalah dalam pembentukan classifier. Algoritma Random Forest digunakan pada penelitian ini karena lebih stabil dalam melakukan klasifikasi tanaman padi sawah(Marsuhandi et al. 2019). Gao et al. (2018) juga menyebutkan Random Forest berhasil mengklasifikasikan tanaman jagung dengan gulma yang ada disekitarnya dengan akurasi tinggi. Bila digunakan dalam klasifikasi tanaman, Random Forest juga memiliki akurasi yang tinggi dan cepat dalam pengolahannya(Tatsumi et al. 2015). Chauhan et al (2021) juga membadingkan penggunaan Random Forest dengan beberapa metode klasifikasi lainnya dimana Random Forest menghasilkan Akurasi tertinggi didalam penelitiannya.

Citra Satelit Landsat-8, Sentinel-2, dan Sentinel-1

Satelit Landsat-8 merupakan produk dari U.S. Geological Survey yang telah digunakan sejak tahun 1972. Satelit Landsat-8 saat ini memiliki resolusi maksimum 15-meter per piksel untuk beberapa band yang disediakan. Arsip citra Landsat-8 dapat diakses dari April 2013 dengan periode waktu setiap 16 hari sekali. Landsat-8 memiliki band 1 sampai band 10. Patunjuk lebih lanjut mengenai Landsat-8 dapat dilihat pada buku panduan Landsat-8 (USGS, 2019). Indeks NDVI, EVI, NDBI, NDWI, dan VARI dapat diturunkan dari Landsat-8 ini.

Sentinel-2 merupakan satelit dari *copernicus program* yang dapat digunakan untuk bidang pertanian, maritim, pengamatan salju dan banjir dan lainnya. Sentinel-2 memiliki 2 buah satelit yaitu Sentinel-2A dan Sentinel-2B. Gabungan dari kedua satelit Sentinel 2A dan 2B tersebut dapat menghasilkan citra dalam jeda waktu per-5 hari. Selain lebih cepat, Sentinel-2 juga memiliki resolusi yang lebih tinggi. ukuran piksel Sentinel-2 sebesar $10 \text{ m} \times 10 \text{ m}$, lebih detail dibandingkan Landsat-8 yang memiliki resolusi $30 \text{ m} \times 30 \text{ m}$. Jumlah band Sentinel-2 juga lebih banyak daripada Landsat-8, yaitu 12 band. Indeks NDVI, EVI, NDBI, NDWI, dan VARI juga dapat diturunkan dari Sentinel-2 ini.

Sentinel-1 adalah jenis citra radar yang mampu tembus awan. Artinya tidak ada pixel citra yang bernilai 0 akibat adanya tutupan awan. Hal ini sangat bermanfaat untuk wilayah seperti Indonesia yang cenderung berawan. Akan tetapi jumlah band jenis radar tidak sebanyak band pada citra optik sehingga informasi yang dihasilkan menjadi kurang banyak. Sentinel-1 sendiri menawarkan produk data dalam polarisasi tunggal (HH atau VV) atau ganda (HH + HV atau VV + VH). Perbandingan gambar citra Sentinel-1 dan Sentinel-2 dapat dilihat pada Gambar 1. Dari Gambar 1 terlihat bahwa komposisi warna citra tidak sebanyak citra Sentinel-2, namun tidak terdaoat tutupan awan pada Sentinel-1.

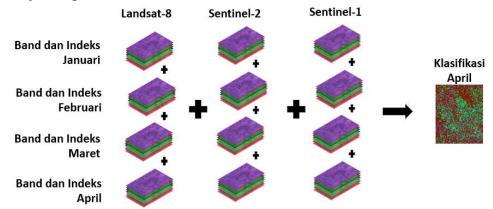


Gambar 1. Contoh Citra Sentinel-1 (kiri) dan Sentinel-2 (kanan).

Citra input deret waktu

Penggunaan informasi band yang tepat dapat meningkatkan akurasi model klasifikasi. Selain band dasar, beberapa indeks vegetasi yang diharapkan mencirikan suatu tanaman tertentu juga digunakan dalam pemodelan. Beberapa indeks tersebut diantaranya adalah EVI, NDWI Gao (1996), NDBI Zha et al. (2003), VARI Gitelson (2002). VARI adalah indeks yang digunakan untuk menangkap biomassa daun pada tajuk jagung.

Input citra yang digunakan dalam penelitian berbentuk komposit bulanan atau temporal. Penggunaan komposit ini dilakukan dengan harapan pertama mengurangi adanya tutupan awan, kedua agar lebih mencirikan suatu tanaman tertentu karena pengamatan dilakukan dalam rentang beberapa bulan sebelumnya. Misalkan untuk prediksi bulan April 2019, maka citra input yang digunakan adalah citra bulan Januari 2019 sampai April 2019 (lihat Gambar 2). Untuk prediksi bulan Mei 2019, maka citra yang digunakan bulan Februari 2019 sampai dengan Mei 2019.



Gambar 2. Ilustrasi Input Citra Deret Waktu

Komputasi awan di Google Earth Engine (GEE)

Satu gambar citra Landsat-8 komposit band 1 sampai band 10 kabupaten tertentu berukuran sekitar 200MB. Maka untuk satu kabupaten pada bulan tertentu saja, proses klasifikasi membutuhkan memori sekitar 1,6GB citra input. Saat klasifikasi dilakukan untuk 1 tahun atau 12 bulan, maka ukuran citra input sekitar 19,2 GB. Ketika klasifikasi dilakukan pada banyak kabupaten dan banyak citra satelit, maka ukuran input data akan semakin besar lagi.

Pemrosesan input citra yang besar tentu memerlukan kemampuan komputasi dengan memori yang besar untuk pengolahan gambar dan proses klasifikasinya. Namun banyak orang atau organisasi yang belum memiliki komputasi dengan kemampuan seperti itu. Oleh karena itu penting untuk memiliki platform komputasi awan. Beberapa penelitian sudah dilakukan dengan memanfaatkan GEE seperti yang dilakukan oleh Tsai et al. (2020) dalam mengklasifikasikan lahan pertanian dan penggunaannya dan Phan et al. (2020) mengklasifikasikan tutupan lahan, dimana pemanfaatan GEE pada kedua penelitian tersebut sangat bermanfaat.

Dalam penelitian ini, pengolahan gambar dan proses klasifikasi dilakukan melalui platform komputasi awan GEE. Berbagai data citra satelit gratis dari awal terbit sampai terbaru telah disediakan oleh GEE. Citra tersebut dapat diolah menjadi tampilan gambar ataupun data berbentuk CSV langsung di GEE. Proses komputasi awan di GEE memungkinkan berbagai macam pengolahan data citra satelit yang kompleks menggunakan kode JavaScript atau Python (Gorelick et al., 2017).

Proses klasifikasi di GEE dilakukan dengan beberapa tahapan. Pertama, batas kabupaten kota dalam bentuk shapefile di upload ke GEE. Batas ini diperlukan agar hasil penelitian dapat dibedakan berdasarkan kabupaten/kota. Kedua, komposit citra landsat-8, citra sentinel 2, dan citra sentinel 1 bebas awan dibuat untuk masing-masing citra satelit. Setelah komposit dihasilkan, nilai piksel yang bersesuaian dengan titik koordinat data pelatihan (KSA Jagung) diekstraksi dalam GEE. Data Hasil ekstrak digunakan sebagai dasar untuk klasifikasi RF. Kemudian akurasi dan sensitifitas model RF dihitung menggunakan *confusion matrix*. Tahap ketiga setelah model klasifikasi terbentuk, model tersebut digunakan untuk mengklasifikasikan semua pixel pada area penelitian. Input citra dalam klasifikasi sama dengan input saat pemodelan.

Data

Data pada penelitian ini diambil dari citra satelit Landsat-8, Sentinel-1, dan Sentinel-2, koordinat hutan lindung, dan KSA jagung dari bulan April— Oktober 2019 yang diolah melalui Google Earth Engine Label hasil KSA yang merupakan peubah respon digabung menjadi 3 kelas yaitu kelas lahan bukan sawah, kelas lahan jagung, dan kelas lahan sawah bukan jagung. Kemudian untuk data koordinat hutan dimasukkan pada kelas lahan bukan sawah untuk menambah sampel khususnya pada bagian hutan atau lahan hijau terbuka non sawah. Untuk peubah prediktor secara lengkap disajikan pada Tabel 1 dibawah ini.

Tabel 1. Peubah prediktor penelitian

| | | 5.1.1.1.1 |
|---|--|---|
| Peubah | Jenis | Deskripsi peubah |
| B1 – B7, B10, B11 (Landsat-8 dan Sentinel-2) | | |
| B1 – B7, B10, B11, B8, B8A dan B12 (Sentinel-2) VH, HH (Sentinel-1) | Minimum, | Statistik <i>composite</i> dari 4 bulan |
| NDBI (Landsat-8 dan Sentinel-2) | Maksimum, Varian, dan Rataan selama 4 | pada suatu koordinat sesuai dengan jenisnya. |
| EVI (Landsat-8 dan Sentinel-2) | Bulan | dengan jemen ja |
| NDVI (Landsat-8 dan Sentinel-2) | | |
| NDWI (Landsat-8 dan Sentinel-2) VARI (Landsat-8 dan Sentinel-2) | | |

Untuk daerah penelitian dipilih Jawa Timur karena sebagai sentra produksi jagung di Indonesia, adapun kabupaten yang dipilih berdasarkan banyaknya jumlah sampel KSA jagung di Jawa Timur sehingga menghasilkan kabupaten amatan pada Tabel 2.

Tabel 2. kabupaten penelitian

| Kabupaten | Jumlah Amatan KSA jagung |
|------------------|--------------------------|
| Kab. Sumenep | 6908 |
| Kab. Jember | 4136 |
| Kab. Malang | 4032 |
| Kab. Tuban | 4031 |
| Kab. Lamongan | 3636 |
| Kab. Bojonegoro | 3192 |
| Kab. Kediri | 2964 |
| Kab. Probolinggo | 2956 |
| Kab. Banyuwangi | 2856 |
| Kab. Ponorogo | 2796 |

Pengolahan

Persiapan Data

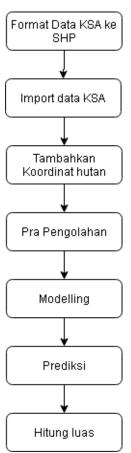
Tahapan pertama pada pembentukan penelitian ini adalah pengolahan data titik koordinat KSA jagung dan beserta atributnya menjadi data spasial titik dalam format SHP longitude latitude. Kemudian data spasial titik, batas wilayah kabupaten, dan peta hutan di upload menjadi asset GEE. Ambil koordinat wilayah hutan secaea acak untuk menambah sampel KSA Jagung. Selanjutnya dilakukan proses ekstrasi data citra satelit di GEE pada koordinat sampel KSA Jagung dan koordinat hutan. Data-data band dasar dari citra satelit juga digunakan untuk membuat indeks spektral yang digunakan pada penelitian ini, yaitu EVI, MNDWI, NDBI, VARI, NDVI.

Pra-Pengolahan

Pada tahap ini dilakukan pembentukan indeks spektral pada GEE, kemudian dihitung nilai komposit bulanan berupa minimum, maksimum, rataan dan variannya. Selain menghitung indeks spektral, perlu juga dilakukan masking pada citra satelit. Masking dilakukan untuk menentukan apakah suatu data dengan tutupan pada koordinat tertentu sudah cukup berkualitas digunakan, sehingga dengan masking diharapkan data yang diolah tetap berkualitas meskipun terjadi tutupan awan.

Pembentukan model dan Proses Prediksi

Pembentukan model klasifikasi dengan menggunakan *Random Forest* dengan 3 kelas. Model yang dibentuk terdiri dari beberapa kombinasi yaitu: 1 satelit, 2 satelit dan 3 satelit sekaligus. Pembentukan model dan proses prediksi dilakukan dengan bantuan Google Earth Engine, data hasil pra pengolahan kemudian diklasifikasikan dengan *Random Forest*. Proses pembentukkan model klasifikasi dilakukan tiap bulan pada masing-masing kabupaten amatan, kemudian titik diluar sampe KSA dilakukan prediksi dengan model yang terbentuk, diagaram alur pengolahan dapat dilihat pada Gambar 3.

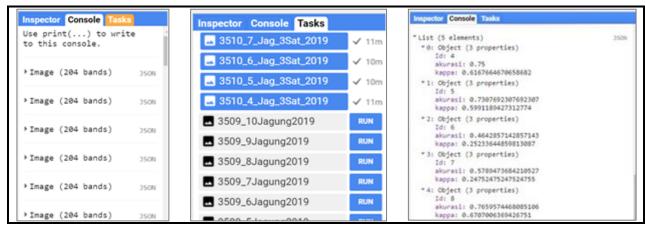


Gambar 3. Diagram Alur Untuk Proses Pengolahan

HASIL DAN PEMBAHASAN

Proses pembentukan model klasifikasi lahan jagung dan prediksinya untuk semua kabupaten dan bulan terpilih dilakukan secara bersamaan di *google earth engine* (GEE). Dari Gambar 4 bagian kiri terlihat bahwa jumlah lapisan gambar yang terbentuk akan ada sebanyak bulan × kabupaten. Misal klasifikasi dilakukan terhadap 1 kabupaten untuk 12 bulan, maka akan ada 12 lapisan gambar.

Setiap lapisan gambar pada penelitian ini terdiri dari jumlah band yang berbeda-beda tergantung komposit bulanan dan percobaan gabungan citra yang digunakan. Misalkan ketika menggunakan 3 kombinasi citra satelit tentu jumlah band untuk satu lapisan gambar akan lebih banyak daripada percobaan yang menggunakan 2 kombinasi citra satelit. Pada Gambar 4, contoh jumlah band untuk satu lapisan gambar sebanyak 204 band. Proses penyusunan 1 lapisan gambar di GEE ini membutuhkan waktu sekitar 1 detik.



Gambar 4. Contoh Jumlah lapisan Citra untuk Prediksi Setiap Daerah dan Bulan (kiri), Akurasi hasil klasifikasi pada GEE (tengah), dan Waktu Download Hasil Klasifikasi (kanan)

Setelah dilakukan klasifikasi untuk setiap kabupaten dan bulan, maka proses selanjutnya adalah mengunduh gambar untuk menyeleksi pixel sesuai dengan definisi potensi luas baku lahan jagung. Misalkan pada penelitian ini telah didefinisikan bahwa potensi luas baku lahan jagung adalah pada pixel yang dalam minimal 3 bulan terklasifikasi sebagai lahan jagung. Maka setelah gambar hasil klasifikasi diunduh lalu dipilih pixel yang memiliki kriteria tersebut. Potensi total luas baku lahan jagung adalah total luasan pixel terpilih. Proses unduh gambar hasil klasifikasi dapat dilakukan secara bersamaan dengan memencet run seperti ditunjukkan dalam Gambar 4 bagian tengah. Waktu yang diperlukan untuk mengunduh gambar sekitar 10 sampai 11 menit. Waktu pengunduhan ini akan semakin bertambah jika area yang diunduh semakin luas.

Output dari hasil klasifikasi GEE berupa *geo tiff* akan dihitung menggunakan aplikasi R, namun untuk akurasi model klasifikasi telah disediakan oleh GEE. Contoh pengihtungan akurasi dapat dilihat pada Gambar 4 bagian kanan. Akurasi output dari GEE ini dapat dihitung berdasarkan rata-rata dari klasifikasi semua kabupaten dan bulan yang dilakukan seperti tertera pada Tabel 3 ataupun rataan kabupaten seperti Tabel 4.

| Tahel 3 Rataan | akurasi kanna | dan sensitifitas untuk | beberana gabungan satelit |
|----------------|---------------|------------------------|---------------------------|

| | Rataan Akurasi | Rataan Kappa | Rataan Sensitifitas Kelas | | |
|------------------------|-------------------|-----------------|---------------------------|-------------------|-----------------------------|
| Satelit | | | Lahan 3ukan Sawah | Lahan Jagung*) | Lahan Sawah Bukan Jagung |
| Sentinel 1 | 0,6700 | 0,3400 | 0,5200 | 0,7900 | 0,3200 |
| Sentinel 2 | 0,7587 | 0,5217 | 0,4738 | 0,8631 | 0,5393 |
| Landsat-8 (Ls-8) | 0,7664 | 0,5365 | 0,5060 | 0,8608 | 0,5635 |
| Sentinel 1 & 2 | 0,7659 | 0,5338 | 0,5181 | 0,8700 | 0,5245 |
| Sentinel 1 & Ls-8 | 0,7635 | 0,5388 | 0,4887 | 0,8782 | 0,5434 |
| Sentinel 2 & Ls-8 | 0,7903 | 0,5844 | 0,4837 | 0,8923 | 0,6154 |
| Sentinel 1, 2 dan LS-8 | 0,7860 | 0,5752 | 0,5143 | 0,8953 | 0,5827 |

^{*}catatan: lahan jagung baik yang ditanam di sawah maupun bukan sawah

Dari hasil klasifikasi, akurasi tertinggi diperoleh pada model dengan menggunakan satelit Sentinel-2 dan Landsat-8. Penggunaan kedua satelit tersebut mampu mengalahkan penggunaan ketiga satelit namun dengan nilai yang tidak terlalu tinggi perbedaannya. Dilihat dari nilai sensitifitas terlihat bahwa sensitifitas lahan jagung lebih tinggi daripada kelas lain. Idealnya nilai sensitifitas antar kelas sama-sama tinggi. Hal ini mengindikasikan bahwa model cenderung lebih sensitif memprediksi suatu area sebagai jagung.

Tabel 4 menggambarkan tingkat akurasi dari model dengan satelit Sentinel-2 dan Landsat-8 untuk masing-masing kabupaten. Dari Tabel 4 terlihat bahwa akurasi model di masing-masing kabupaten berkisar antara 0.7-0.8. Untuk rataan sensitifitas, rata-rata untuk kelas jagung sudah cukup tinggi, sedangkan kelas lahan bukan sawah ada yang tinggi dan ada yang rendah.

Tabel 4. Rataan Akurasi, Kappa dan sensitifitas Citra Satelit Sentinel-2 dan Landsat-8 pada Kabupaten Terpilih

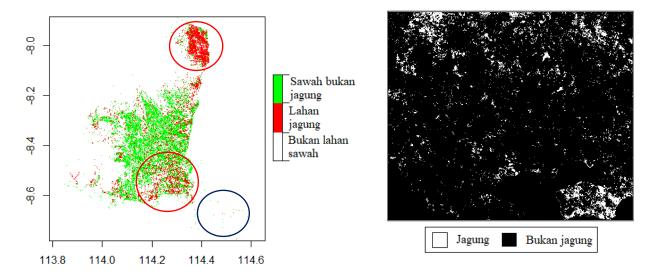
| | Rataan Rataan | | Rataan Sensitifitas Kelas | | |
|------------------|---------------|--------|---------------------------|-------------------|-----------------------------|
| Satelit | Akurasi | Kappa | Lahan Bukan Sawah | Lahan Jagung*) | Lahan Sawah Bukan Jagung |
| Kab. Ponorogo | 0,7688 | 0,4824 | 0,1405 | 0,9185 | 0,5727 |
| Kab. Kediri | 0,8008 | 0,5084 | 0,1000 | 0,9127 | 0,6057 |
| Kab. Malang | 0,7705 | 0,6371 | 0,8525 | 0,8581 | 0,5148 |
| Kab. Jember | 0,8580 | 0,7651 | 0,9053 | 0,9225 | 0,5847 |
| Kab. Banyuwangi | 0,8594 | 0,7478 | 0,9481 | 0,7063 | 0,7581 |
| Kab. Probolinggo | 0,7763 | 0,6297 | 0,6650 | 0,9042 | 0,6651 |
| Kab. Bojonegoro | 0,7518 | 0,4809 | 0,1699 | 0,9430 | 0,5873 |
| Kab. Tuban | 0,7942 | 0,4370 | 0,1797 | 0,9644 | 0,4449 |
| Kab. Lamongan | 0,8491 | 0,7220 | 0,4640 | 0,9252 | 0,8606 |
| Kab. Sumenep | 0,6738 | 0,4339 | 0,4120 | 0,8682 | 0,5602 |

^{*}catatan: lahan jagung baik yang ditanam di sawah maupun bukan sawah

Nilai sensitifitas yang rendah pada kelas lahan bukan sawah terjadi pada Kabupaten Ponorogo, Kediri, Bojonegoro, Tuban, Lamongan, dan Sumenep. Untuk kelas lahan sawah bukan jagung, nilai sensitifitas model rata-rata masih diantara 0.5-0.6. Akibatnya, dicurigai bahwa model lebih cenderung memprediksi suatu pixel lahan bukan sawah sebagai lahan jagung. Contohnya di Kabupaten Ponorogo. Ketika dilakukan penelusuran pada gambar hasil klasifikasi Kabupaten Ponorogo, nampak beberapa area hutan atau tanah-tanah kering terklasifikasi sebagai lahan jagung. Hasil klasifikasi ini memungkinkan untuk salah ataupun benar, namun tidak ada informasi hasil pengecekan di lapangan untuk memastikan kebenaran hasil klasifikasi. Adanya informasi maupun pengecekan lapangan bermanfaat untuk perbaikan model prediksi jagung.

Hasil klasifikasi areal hutan sebagai jagung memungkinkan benar karena di Ponorogo terdapat areal-areal pinggiran hutan yang di sewa oleh penduduk setempat. Biasanya hutan tersebut ditanami jagung satu atau dua kali setahun diantara sela-sela pohon hutan yang baru ditanam. Hasil klasifikasi tersebut juga memungkinkan salah karena dicurigai di Ponorogo banyak terdapat areal hutan jati kering yang meranggas saat musim kemarau ataupun lahan-lahan kering semak belukar. Kecurigaan ini timbul karena fenologi perubahan antar waktu hutan jati memungkinkan mirip dengan fenologi perubahan antar waktu jagung. Oleh karena itu, diperlukan penelitian lebih lanjut untuk melihat apakah rendahnya sensitifitas kelas lahan bukan sawah di Ponorogo akibat pola hutan jati yang meranggas. Jika hasilnya terbukti, maka diperlukan juga penelitian yang mampu membedakan hutan jati meranggas dengan jagung. Dengan adanya penelitian lebih lanjut tersebut, diharapkan ada peningkatan akurasi maupun sensitifitas model klasiikasi jagung, sehingga peta potensi luas baku lahan jagung yang dihasilkan akan lebih baik lagi.

Selanjutnya dipilih kabupaten dengan nilai rataan akurasi maupun rataan sensitifitas antar kelas yang cukup baik. Kabupaten terpilih akan digunakan untuk contoh tampilan hasil klasifikasi dan contoh penghitungan luas potensi lahan yang ditanami jagung.



Gambar 5. Hasil Klasifikasi Lahan Jagung Bulan April (kiri) dan Pixel Potensi Lahan Baku Jagung (kanan)

Hasil klasifikasi model, tanaman jagung banyak terdapat di Kecamatan Wongsorejo, Tegaldlimo, dan Purwoharjo (lingkaran merah Gambar 5 kiri). Ketiga kecamatan tersebut memang merupakan sentra jagung. Banyak tanaman jagung yang ditanam pada lahan-lahan kering.

Berbeda dengan Ponorogo, di Banyuwangi area hutan banyak diklasifikasikan sesuai kelasnya (bukan lahan sawah). Nampak area hutan sepanjang Ijen sampai Kumitir maupun Alas Purwo secara umum berwarna putih meskipun masih terdapat kesalahan klasifikasi. Terlihat dari lingkaran hitam di Gambar 5 kiri masih terdapat titik-titik pixel bewarna hijau dan merah. Alas Purwo merupakan hutan lindung. Masyarakat sekitar tidak diizinkan memanfaatkan hutan di Alas Purwo sehingga kemungkinan besar klasifikasi titik hijau dan merah di area tersebut adalah kesalahan klasifikasi.

Gambar 5 bagian kanan menunjukkan pixel-pixel terpilih yang memenuhi definisi lahan baku jagung. Dalam penelitian ini, pixel dinyatakan sebagai lahan baku jagung jika dalam 3 bulan teridentifikasi sebagai jagung. Semakin tinggi kriteria banyaknya bulan, misalnya dianggap lahan baku jagung jika dalam 4 bulan terklasifikasi sebagai jagung, maka jumlah pixel terpilih akan semakin sedikit. Artinya luas baku lahan jagung akan semakin kecil jika kriteria minimal bulan semakin banyak.

Luasan lahan jagung ini dapat dihitung dari luasan beberapa bulan maupun luasan masing-masing bulan seperti Tabel 5. Luasan jagung gabungan dari beberapa bulan bukan berarti total dari luas masing-masing bulan. Hal ini disebabkan pixel pada area yang sama akan dihitung sekali saja untuk total luasan antar bulan.

| Tabel 7 Luas po | otensi jagung | di Kabupaten | Banyuwangi . | April – | Oktober 2019 |
|-----------------|---------------|--------------|--------------|---------|--------------|
| | | | | | |

| 1 300 | 1 2 1 | | |
|-----------|---------------------|-----------------|-----------------------------|
| Bulan | Lahan Bukan Sawah*) | Lahan Jagung*)) | Lahan Sawah Bukan Jagung |
| April | 749415.42 | 22256.82 | 81232.92 |
| Mei | 746621.55 | 33579.09 | 72704.52 |
| Juni | 728941.32 | 58992.3 | 64971.54 |
| Juli | 724038.84 | 51920.19 | 76946.13 |
| Agustus | 731526.12 | 52314.93 | 69064.11 |
| September | 738949.68 | 58797.72 | 55157.76 |
| Oktober | 750971.07 | 47043.9 | 54890.19 |
| | | | |

catatan: *meliputi nilai 0 di luar area Banyuwangi karena gambar yang terunduh berbentuk kotak **lahan jagung baik yang ditanam di sawah maupun bukan sawah

Pada penelitian ini kelas lahan bukan sawah di kategorikan 0. Daerah yang terdapat tutupan awan penuh juga bernilai 0. Daerah di luar batas kabupaten juga bernilai 0. Gambar hasil klasifikasi yang terunduh dari GEE adalah gambar raster berbentuk kotak sehingga daerah terunduh meliputi area kotak di sekitar batas longitude dan latitude terluar. Akibatnya total dari kelas lahan bukan sawah, lahan jagung, dan lahan sawah bukan jagung tidak berarti sebagai total luas wilayah Banyuwangi. Oleh karena lahan bukan sawah tidak

menjadi fokus penelitian, maka tidak dilakukan penghapusan wilayah diluar batas kabupaten yang telah dibuat menjadi 0 tersebut.

Dari hasil prediksi setiap bulan terlihat bahwa luas lahan jagung yang paling kecil di bulan April dan Mei. Bulan April dan Mei memang merupakan puncak panen padi sehingga lebih sedikit rumah tangga pertanian yang menanam jagung di lahan sawah (dapat di lihat pada BRS Luas Panen dan Produksi Padi di Kabupaten Banyuwangi 2020).

Luas LBS Banyuwangi berkisar 80an ribu hektar. Hasil survei ubinan BPS menunjukkan bahwa rumah tangga padi yang menanam jagung di lahan sawah sekitar 15 persen. Maka secara kasar dapat diprediksi LBS yang ditanami jagung berkisar 10an ribu hektar dan yang ditanami selain jagung sekitar 70an ribu hektar. Hal ini nampaknya konsisten dengan hasil klasifikasi jagung bulanan pada Tabel 5. Petunjuk kekonsitenan data hasil prediksi juga dapat diihat dari total lahan sawah bukan jagung dan lahan jagung. Total kedua kelas tersebut di Tabel 5 sekitar 110an ribu hektar. Dibandingkan dengan luasan LBS, maka area penanaman jagung bukan di area sawah sekitar 30an ribu hektar atau sekitar 60-70 persen luasan jagung. Data ini konsisten dengan hasil survei ubinan yang menyatakan lebih dari 50 persen rumah tangga jagung menanam jagung di areal bukan sawah.

Adanya indikasi bahwa data hasil prediksi model jagung konsisten dengan data laporan yang ada memberikan peluang bahwa kajian awal penggunaan GEE ini dapat dimanfaatkan untuk pemetaan potensi lahan baku jagung. Beberapa perbaikan yang perlu dilakukan diantaranya penambahan sampel pembentukan model serta perbaikan algoritma yang mampu membedakan jagung dengan lahan-lahan kering.

KESIMPULAN

Pertanian, meskipun sebagai lapangan usaha yang telah terbukti *robust* terhadap pandemi namun masih memerlukan inovasi dan pengembangan dalam pelaporannya sehingga hasil dari pertanian dapat dilaporkan secara tepat dan cepat. Dari kajian awal pemanfaatan *cloud computing google earth engine* ini memberikan peluang pelaporan yang tepat dan cepat seperti yang telah disajikan dalam penelitian ini. Pembentukan model dan pengklasifikasian lahan jagung dapat dilakukan dalam hitungan detik. Proses unduh gambar hasil klasifikasi cukup cepat berkisar 10 menit. Hasil akurasi dari model *machine learning* juga menunjukkan akurasi yang cukup tinggi yaitu 0.79, bahkan di beberapa kabupaten sampel hampir mencapai akurasi 0.85.

Peta potensi lahan jagung juga menunjukkan kekonsitenan dengan data yang ada. Misalkan di Kabupaten Banyuwangi, hasil prediksi model banyak terdapat di beberapa kecamatan yang memang merupakan sentra jagung. Daerah areal hutan juga tepat diprediksi sebagai lahan bukan sawah. Akan tetapi pada kabupaten seperti Ponorogo areal hutan diklasifikasikan sebagai jagung. Kebenaran hasil klasifikasi belum dapat ditelusuri karena tidak ada informasi dari lapangan.

Selain informasi lapangan, terdapat beberapa keterbatasan pada penelitian ini yang perlu disempurnakan untuk selanjutnya. Beberapa hal yang perlu diperhatikan diantaranya jumlah amatan untuk data latih yang terbatas, perlu lebih banyak informasi tanaman jagung di areal bukan sawah, serta perbaikan algoritma terutama untuk membedakan jagung dengan hutan jati yang meranggas ataupun lahan-lahan kering semak belukar.

DAFTAR PUSTAKA

Ballesteros, R et al.. 2020. Assessment of Maize Growth and Development with High- and Medium-Resolution Remote Sensing Products

BIG. 2020. deputi bidang informasi geospasial tematik badan informasi geospasial No 4 tahun 2020

Bappenas. (2014). Studi Identifikasi Ketahanan Pangan dan Preferensi Konsumen terhadap Konsumsi Bahan Pangan Pokok Kedelai. Jakarta: Bappenas.

Bappenas (2015). Evaluasi Implementasi Kebijakan Lahan Pertanian Pangan Berkelanjutan (LP2B)

BPS. BRS Pertumbuhan Ekonomi Indonesia Triwulan IV-2020 No. 13/02/Th. XXIV, 5 Februari 2021. https://www.bps.go.id/pressrelease/download.html?nrbvfeve=MTgxMQ%3D%3D&sdfs=ldjfdifsdjkfahi&twoadfnoarfeauf=MjAyMS0wOC0zMCAxMzo1MzozOA%3D%3D

[BPS] Badan Pusat Statistik. 2021. Analisis Produktivitas Jagung dan Kedelai di Indonesia. Badan Pusat Statistik, Jakarta.

[BPS] Badan Pusat Statistik Provinsi Jawa Timur. 2021. Berita Resmi Statistik. Badan Pusat Statistik Provinsi Jawa Timur, Surabaya.

- [BPS] Badan Pusat Statistik, BPS Provinsi Jawa Tengah. 2018. Berita Resmi Statistik Luas Panen dan Produksi Padi di Jawa Tengah 2018. Badan Pusat Statistik Provinsi Jawa Tengah, Semarang.
- [BPS] Badan Pusat Statistik. 2018. Upaya Perbaikan Data Padi Dengan Metode Kerangka Sampel Area (KSA) 2018. Badan Pusat Statistik, Jakarta.
- [BPS] Badan Pusat Statistik. 2019. Statistik Indonesia 2019. Badan Pusat Statistik, Jakarta.
- Breiman L. 2001. Random Forests. Machine learning. 45(1). pp.5-32.
- Chauhan, M. D. (2021). Detection of Maize Disease Using Random Forest Classification Algorithm. Turkish Journal of Computer and Mathematics Education (TURCOMAT), 12(9), 715-720.
- Dirgahayu D. 2015. Identifikasi Parameter Pertumbuhan Tanaman Padi Menggunakan Data EVI Modis Multitemporal (Studi Kasus di Sulawesi Selatan). Di dalam : Prosiding Pertemuan Ilmiah Tahunan XX dan Kongres. [LAPAN, Jakarta, 2015]. DKI Jakarta(ID) : LAPAN hal 182 [diunduh 27 November 2019 jam 23.00]. tersedia pada http://repository.lapan.go.id//index.php?p=show_detail&id=2429.
- Furht B, Villanustre F. 2016. Introduction to *big data*. In *Big data* technologies and application. Springer, Cham. pp. 3-11.
- Gao, J., Nuyttens, D., Lootens, P., He, Y., & Pieters, J. G. (2018). Recognising weeds in a maize crop using a random forest machine-learning algorithm and near-infrared snapshot mosaic hyperspectral imagery. Biosystems Engineering, 170, 39-50.
- Gislason PO. Benediktsson JA, Sveinsson JR. 2006. *Random Forests* for land cover classification. Pattern Recognition Letters. 27(4). pp.294-300.
- Gumma, MK et all. 2019. Agricultural cropland extent and areas of South Asia derived using Landsat satellite 30-m time-series big-data using random forest machine learning algorithms on the Google Earth Engine cloud. GIScience & Remote Sensing. https://doi.org/10.1080/15481603.2019.1690780
- Gumma, MK et al.. 2020. Agricultural cropland extent and areas of South Asia derived using Landsat satellite 30-m time-series big-data using random forest machine learning algorithms on the Google Earth Engine cloud
- Jiong, J et al.. 2017. Automated cropland mapping of continental Africa using Google Earth Engine cloud computing
- Jiong, J et al.. 2017. Nominal 30-m Cropland Extent Map of Continental Africa by Integrating Pixel-Based and Object-Based Algorithms Using Sentinel-2 and Landsat-8 Data on Google Earth Engine
- Marsuhandi AH, Soleh AM, Wijayanto H, Dirgahayu DD. 2019. Pemanfaatan Ensemble Learning Dan Penginderaan Jauh Untuk Pengklasifikasian Jenis Lahan Padi . Di dalam : Seminar Nasional Official Statistics 2019. [STIS, Jakarta 24 September 2019]. Jakarta (ID) : STIS. hal 46 [diunduh 11 November 2019 jam 15.00]. tersedia pada https://semnas.stis.ac.id/files/Kumpulan_abstraksi_seminar_nasional_offstat_2019.pdf.
- Pal M. 2005. *Random Forest* classifier for remote sensing classification. International Journal of Remote Sensing, 26(1), pp.217-222.
- Phan, T. N., Kuch, V., & Lehnert, L. W. (2020). Land Cover Classification using Google Earth Engine and Random Forest Classifier—The Role of Image Composition. Remote Sensing, 12(15), 2411.
- Kenichi Tatsumi, Yosuke Yamashiki, Miguel Angel Canales Torres, Cayo Leonidas Ramos Taipe. 2015. Crop classification of upland fields using Random forest of time-series Landsat 7 ETM+ data. Computers and Electronics in Agriculture, Volume 115, Pages 171-179
- Triscowati DW, Sartono B, Kurnia A, Dirgahayu DD, Wijayanto AW. 2019. Klasifikasi Fase Tanaman Padi Menggunakan Supervised *Random Forest* Pada Data Multitemporal Citra Landsat-8. Di dalam: Seminar Nasional Penginderaan Jarak Jauh. [The Margo Hotel Depok, Jawa Barat 17 Juli 2019]. Jawa Barat(ID): LAPAN hal 44 [diunduh 11 November 2019 jam 15.00]. tersedia pada https://semnas.stis.ac.id/files/Kumpulan_abstraksi_seminar_nasional_offstat_2019.pdf.
- Tsai YH, Stow D, Chen HL, Lewison R, An L, Shi L. 2018. Mapping Vegetation and Land Use Types in Fanjingshan National Nature Reserve Using Google Earth Engine. Remote Sensing. 10(6):927. https://doi.org/10.3390/rs10060927
- [USGS]Departement of the Interior, U. S. Geological Survey (US). 2019. Landsat 8 (L8) Data User Handbook. USGS, South Dakota (US).
- Vina, A et al.. 2004. Monitoring Maize (Zea mays L.) Phenology with Remote Sensing
- Xu H. 2006. Modification of normalised difference water index (NDWI) to enhance open water features in remotely sensed imagery. International journal of remote sensing. 27(14), pp.3025-3033.
- Zha Y, Gao, J, Ni S. 2003. Use of normalized difference built-up index in automatically mapping urban areas from TM imagery. International journal of remote sensing. 24(3), pp.583-594.

-